script_P5

brunop31

06/07/2020

```
library(dplyr)
library(FactoMineR)
library(factoextra)
library(gridExtra)
select <- dplyr::select
#J'importe les données de la FAO et je sélectionne les colonnes
#qui m'intéresse
pop_2008<-read.csv("pop_2008.csv", encoding = "UTF-8")%>%
  select("Zone", "pop2008" = "Valeur")
pop_2018<-read.csv("pop_2018.csv", encoding = "UTF-8")%>%
  select("Zone", "pop2018" = "Valeur")
prot_ani_hab<-read.csv("prot_ani_habitant.csv", encoding = "UTF-8")%>%
  select("Zone", "prot_ani" = "Valeur")
prot_hab<-read.csv("prot_habitant.csv", encoding = "UTF-8")%>%
  select("Zone", "prot" = "Valeur")
kcal_hab<-read.csv("kcal_habitant.csv", encoding = "UTF-8")%>%
  select("Zone", "kcal" = "Valeur")
pib_hab<-read.csv("pib_habitant.csv", encoding = "UTF-8")%>%
  select("Zone", "pib" = "Valeur")%>%group_by(Zone)%>%
  summarise_if(is.numeric, round)
#Je regroupe les données dans un même tableau
df<-left_join(prot_ani_hab, pop_2008)%>%
 left_join(pop_2018)%>%left_join( prot_hab)%>%
  left_join(kcal_hab)%>%left_join(pib_hab)
#Je vérifie si il y a des données non renseigné
sapply(df,function(x) sum(is.na(x)))
```

prot

kcal

pib

##

Zone prot_ani pop2008 pop2018

0 0 1 0 0 1


```
na_table<-filter(df, is.na(pop2008)|is.na(pib))</pre>
#Je complete les données non renseigné et je raccourci
#les noms de pays trop long
df$Zone<-df$Zone%>%as.vector()
df["138","Zone"]<-"Royaume-Uni"</pre>
df["135","Zone"] <- "Corée du Nord"
df["131", "Zone"] <- "Corée du Sud"
df["133","Zone"]<-"Laos"</pre>
df["168", "Zone"] <- "Venezuela"
df["150","pop2008"]<- 33060
df["35","pib"]<-24971
#Je fais les calculs pour obtenir les colonnes voulues
df<-df%>%
 mutate(pop_diff = round((pop2018 -pop2008)*100/pop2008,1),
         prot_ani_prct = round(prot_ani*100/prot,0))%>%
  select(-"prot_ani", -"pop2018", -"pop2008")
```

```
#Je construit mon dendrogramme à partir des variables demandées
df_table<-df
row.names(df_table)<-df_table$Zone</pre>
df_table<-select(df_table, -"Zone",-"pib")</pre>
df_table.cr<-scale(df_table, center = T, scale = T)</pre>
d.df_table<- dist(df_table.cr)</pre>
cah.ward <- hclust(d.df_table,method="ward.D2", )</pre>
#Je déssine mon arbre
fviz_dend(cah.ward,
          k = 5,
                                           # Label size
          cex = 0.4,
          palette = "jco",
                                         # Color palette see ?qqpubr::qqpar
          rect = TRUE, rect_fill = TRUE, # Add rectangle around groups
          rect_border = "jco",
                                           # Rectangle color
          labels_track_height = 5
                                         # Augment the room for labels
```

Cluster Dendrogram

#Je renomme les cluster
df\$clust<-as.vector(df\$clust)</pre>

df[df\$clust == 1,]\$clust<-"pays sous développés"</pre>



```
#Je récupère les cluster former par mon algorithme
groupes.cah <- cutree(cah.ward,k=5)

a<-as.data.frame(sort(groupes.cah))%>%select(clust = "sort(groupes.cah)")

#Je crée un fichier csu pour enregistrer mes groupes
write.csv(a, file = "liste_pays.csv")

a$Zone<-row.names(a)

df<-df%>%inner_join(a)


## Joining, by = "Zone"


#Je calcul les centre des clusters
centroide<-select(df, -"Zone")%>%
    group_by(clust)%>%
    summarise_if(is.numeric, function(x) round(mean(x),1))

#Je crée un fichier csu pour enregistrer mes clusters
write.csv(centroide, file = "centroide.csv", row.names = FALSE)
```

```
df[df$clust == 2,]$clust<-"autres"
df[df$clust == 3,]$clust<-"occident"
df[df$clust == 4,]$clust<-"pays en transition"
df[df$clust == 5,]$clust<-"pays à forte démographie"
df$clust<-as.factor(df$clust)</pre>
#Je fais une pca sur mes données
res.pca <- PCA(df_table, graph = FALSE)
#J'affiche le cercle des corrélations
```

fviz_pca_var(res.pca,repel = TRUE)





Shapiro-Wilk normality test

##


data: df\$prot

```
theme(axis.text.y = element_blank())
shapiro.test(df$kcal)
##
##
   Shapiro-Wilk normality test
## data: df$kcal
## W = 0.98133, p-value = 0.02066
y<-ggplot(df, aes(pop_diff))+
  geom_histogram(aes(y=..density..), bins = 30,
                 colour="black", fill="white")+
 geom_density(alpha=.2, fill="#FF6666")+
  geom_vline(aes(xintercept=mean(pop_diff)),
            color="blue", linetype="dashed", size=1)+
  theme(axis.text.y = element_blank())
shapiro.test(df$pop_diff)
##
  Shapiro-Wilk normality test
##
##
## data: df$pop_diff
## W = 0.95572, p-value = 3.012e-05
z<-ggplot(df, aes(prot_ani_prct))+</pre>
  geom_histogram(aes(y=..density..), bins = 30,
                 colour="black", fill="white")+
 geom_density(alpha=.2, fill="#FF6666")+
 geom_vline(aes(xintercept=mean(prot_ani_prct)),
            color="blue", linetype="dashed", size=1)+
 theme(axis.text.y = element_blank())
shapiro.test(df$prot_ani_prct)
##
## Shapiro-Wilk normality test
##
## data: df$prot_ani_prct
## W = 0.95562, p-value = 2.944e-05
v<-ggplot(df, aes(pib))+
  geom_histogram(aes(y=..density..), bins = 30,
                 colour="black", fill="white")+
geom_density(alpha=.2, fill="#FF6666")+
  geom_vline(aes(xintercept=mean(pib)),
            color="blue", linetype="dashed", size=1)+
  theme(axis.text.y = element_blank())
shapiro.test(df$pib)
```


```
##
    Shapiro-Wilk normality test
##
##
## data: df$pib
## W = 0.70032, p-value < 2.2e-16
###On rejette l'hypothèse nulle au seuil de 1%
###Les variables retenues sont kcal et prot
#J'affiche les courbe de densité de chacune des variables
grid.arrange(w,x,y,z,v, ncol=2, nrow = 3)
density
                                                 density
                                                         2000
                                                                   2500
                                                                                     3500
             60
                         90
                                                                            3000
                                   120
                       prot
                                                                       kcal
 density
                                                 density
                                    60
                                                            20
                            40
                     pop_diff
                                                                  prot_ani_prct
 density
                             80000
                                         120000
      Ó
                 40000
                        pib
#J'extrait les pays de mes groupes dans 5 table différentes
df_1<-df%>%filter(clust == "pays sous développés")%>%
  select(-"clust")
df_2<-df%>%filter(clust == "pays en transition")%>%
  select(-"clust")
df_3<-df%>%filter(clust == "pays à forte démographie")%>%
  select(-"clust")
df_4<-df%>%filter(clust == "autres")%>%
  select(-"clust")
```

```
df_5<-df%>%filter(clust == "occident")%>%
    select(-"clust")
```

Warning: 'fun.y' is deprecated. Use 'fun' instead.



```
x2<-ggplot(filter(df, clust == "pays sous développés"), aes(kcal))+</pre>
  geom_histogram(aes(y=..density..), bins = 10,
                 colour="black", fill="white")+
 geom_density(alpha=.2, fill="#FF6666")+
  geom_vline(aes(xintercept=mean(kcal)),
            color="blue", linetype="dashed", size=1)+
  theme(axis.text.y = element_blank())
#J'éffectue un test de normalité pour kcal sur les 2 groupes
shapiro.test(filter(df, clust == "pays sous développés")$kcal)
##
## Shapiro-Wilk normality test
## data: filter(df, clust == "pays sous développés")$kcal
## W = 0.9698, p-value = 0.4202
shapiro.test(filter(df, clust == "pays en transition")$kcal)
##
## Shapiro-Wilk normality test
## data: filter(df, clust == "pays en transition")$kcal
## W = 0.95841, p-value = 0.2329
#j'affiche les courbes
grid.arrange(x1,x2, ncol=2, nrow = 1)
```



```
###Test de fisher (variance)
var.test(df_1$kcal, df_2$kcal)
```


```
##
## F test to compare two variances
##
## data: df_1$kcal and df_2$kcal
## F = 1.7916, num df = 35, denom df = 32, p-value = 0.09905
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.8941111 3.5515242
## sample estimates:
## ratio of variances
## 1.791575
```

##p-value = 0.09905 les variances sont différentes au seuil de 10%


```
#Je choisis le groupe occident et je réalise une pca par rapport
#au variable pop_diff et pib
df_table_5<-df_5

row.names(df_table_5)<-df_table_5$Zone
df_table_5<-select(df_table_5, "pib", "pop_diff")

res.pca <- PCA(df_table_5, graph = FALSE)</pre>
```



fviz_pca_ind(res.pca, col.ind = "x")



```
#J'établis la liste des pays du plus intéressant au moins intéressant
#pour nous.
#La variable x est un mélange égal de la variable pib et de la
#variable pop_diff
pays_liste<-res.pca[["ind"]][["coord"]]%>%as.data.frame()
pays_liste$Zone<-rownames(pays_liste)
pays_liste<-pays_liste%>%select(Zone, Dim.1)%>%arrange(desc(Dim.1))
pays_liste
```

```
Zone
                                                            Dim.1
## Luxembourg
                                          Luxembourg 3.930617102
                               Chine - RAS de Macao
## Chine - RAS de Macao
                                                      2.842400609
## Suisse
                                              Suisse 1.778446933
## Norvège
                                             Norvège 1.748649719
## Australie
                                           Australie 1.569058544
## Irlande
                                             Irlande 1.459909881
## Israël
                                              Israël 1.407317487
## Islande
                                             Islande 1.306202806
## États-Unis d'Amérique
                               États-Unis d'Amérique 0.891733052
## Canada
                                              Canada 0.743860375
## Suède
                                               Suède 0.712306321
## Nouvelle-Zélande
                                    Nouvelle-Zélande 0.647511948
## Danemark
                                            Danemark 0.574614825
## Autriche
                                            Autriche 0.488283165
## Chine - RAS de Hong-Kong Chine - RAS de Hong-Kong 0.445411038
                                         Royaume-Uni 0.364846866
## Royaume-Uni
```

```
## Belgique
                                             Belgique 0.348661361
## Pays-Bas
                                             Pays-Bas 0.206769408
## Finlande
                                             Finlande 0.181866706
## Kazakhstan
                                          Kazakhstan 0.135105077
## Malte
                                                Malte 0.052536407
## Allemagne
                                           Allemagne 0.012742290
## France
                                               France 0.006090978
## Argentine
                                            Argentine -0.242605290
## Corée du Sud
                                        Corée du Sud -0.242972243
## Italie
                                               Italie -0.299398263
## Brésil
                                               Brésil -0.459575873
## Espagne
                                              Espagne -0.556929279
## Slovénie
                                             Slovénie -0.566712863
## Tchéquie
                                             Tchéquie -0.680519213
## Estonie
                                              Estonie -0.989388353
## Fédération de Russie
                                Fédération de Russie -1.047054239
## Portugal
                                             Portugal -1.162378856
## Monténégro
                                           Monténégro -1.184902963
## Pologne
                                              Pologne -1.192754433
## Hongrie
                                              Hongrie -1.319279643
## Bélarus
                                              Bélarus -1.340233107
## Grèce
                                                Grèce -1.399711893
## Croatie
                                              Croatie -1.515616659
## Albanie
                                              Albanie -1.728938036
                                             Roumanie -1.750421111
## Roumanie
## Lettonie
                                             Lettonie -2.026545134
## Lituanie
                                             Lituanie -2.149005444
shapiro.test(df_1$kcal)
##
##
  Shapiro-Wilk normality test
##
## data: df_1$kcal
## W = 0.9698, p-value = 0.4202
shapiro.test(df_2$kcal)
##
##
   Shapiro-Wilk normality test
##
## data: df_2$kcal
## W = 0.95841, p-value = 0.2329
```