

Prédisez la demande en électricité



SOMMAIRE

- Exucative summary
- Présentation des données utilisées
- Correction de l'effet température
- Dessaisonalisation
- Prévission de la consommation méthode Holt-Winters
- Prévission de la consommation méthode SARIMA
- Conclusion
- Bilan

Exucative Summary

ENERCOOP souhaite un modèle permettant de déterminer la demande en électricité des utilisateurs.

Trouver un modèle efficace pour faire une telle prédiction ?

Insight et recommandation:

La modèle SARIMA(0,0,0)(0,1,1)[12] sur la consommation ajusté de la température est très fiable et répond à la problématique.


Présentation des données utilisées

« Traitement, nettoyage, analyse »

Consommation de l'électricité en France

Source : <https://www.rte-france.com/eco2mix/telecharger-les-indicateurs>

Date	Consommation
2012-01	51086
2012-02	54476
2012-03	43156
2012-04	40176
2012-05	35257
2012-06	33219
2012-07	34141
2012-08	32247



Degrés jours Unifiés

Source : <https://cegibat.grdf.fr/simulateur/calcul-dju>

Sur une période et un lieu donnés : somme des écarts entre une température de référence (généralement 18 degrés) et la température moyenne journalière.

Données manquantes
en 2020

Année	JAN	FÉV	MAR	AVR	MAI	JUN	JUI	AOÛ	SEP	OCT	NOV	DÉC
2020	339.0	249.6	269.2	105.6	85.9	36.2	0.0	0.0	0.0	0.0	0.0	0.0
2019	404.9	268.8	234.3	177.2	126.8	35.7	10.0	11.8	45.3	136.9	282.6	327.3
2018	303.4	432.6	314.4	128.9	74.1	20.1	1.6	13.5	53.7	133.4	282.8	325.9
2017	467.9	278.4	208.9	187.1	87.8	21.4	13.5	20.8	74.5	109.3	282.6	369.0
2016	364.4	321.6	321.1	214.1	100.7	40.8	14.7	13.8	27.3	177.3	285.6	390.8
2015	392.0	365.7	275.7	154.6	104.8	36.4	15.8	16.1	81.8	179.6	196.9	248.1
2014	324.4	281.9	226.6	141.8	112.5	37.3	17.7	36.1	34.4	101.3	223.3	368.2
2013	429.2	402.2	376.6	216.3	161.5	57.6	9.3	19.9	55.3	112.0	303.9	349.5
2012	336.0	435.9	210.5	231.2	93.8	50.4	29.8	14.1	72.6	159.2	296.2	345.9

Degrés jours Unifiés

```
#Je récupère les données DJU de paris(~France)
DJU<-read.csv("DJU.csv", sep = ",", encoding = "latin1", skip = 11)

#Je rajoute les données DJU à ma table principale
for (j in 0:7) {
  for (i in 1:12) {
    conso$DJU[i+j*12]<-DJU[9-j,i+1]
  }
}
```

	Date	Territoire	Qualité	Conso	DJU
1	2012-01	France	Données définitives	51086	336.0
2	2012-02	France	Données définitives	54476	435.9
3	2012-03	France	Données définitives	43156	210.5
4	2012-04	France	Données définitives	40176	231.2
5	2012-05	France	Données définitives	35257	93.8
6	2012-06	France	Données définitives	33219	50.4
7	2012-07	France	Données définitives	34141	29.8

← Colonne DJU
remplit par
les données
téléchargées

Correction de l'effet température

« modèle, indicatrice mois, time »

Modèle

$$y = at + bu + \sum_{i=1}^{12} c_i 1$$

t représente l'évolution temporelle

u correspond au DJU du mois en cours

c L'indicatrice du mois en cours

Création indicatrice mois

```
#Je crée une indicatrice mois dans ma table principale
for (i in 1:12){
  su=rep(0,times=12)
  su[i]=1
  s=rep(su,times=8)
  assign(paste("s",i,sep=""),s)
}

conso_lm<-cbind(conso,s1,s2,s3,s4,s5,s6,s7,s8,s9,s10,s11,s12)
```

[illegible]

Création d'une colonne « time »

```
#Je crée une colonne time qui est une clé primaire et qui me permettra  
#d'étudier et de représenter la série temporelle  
conso$time<-1:nrow(conso)
```

Date	Conso	time	DJU	s1	s2	s3	s4	s5	s6	s7	s8	s9	s10
2012-01	51086	1	336.0	1	0	0	0	0	0	0	0	0	0
2012-02	54476	2	435.9	0	1	0	0	0	0	0	0	0	0
2012-03	43156	3	210.5	0	0	1	0	0	0	0	0	0	0
2012-04	40176	4	231.2	0	0	0	1	0	0	0	0	0	0
2012-05	35257	5	93.8	0	0	0	0	1	0	0	0	0	0
2012-06	33219	6	50.4	0	0	0	0	0	1	0	0	0	0
2012-07	34141	7	29.8	0	0	0	0	0	0	1	0	0	0

Régression linéaire

```
call:
lm(formula = Conso ~ time + s1 + s2 + s3 + s4 + s5 + s6 + s7 +
    s8 + s9 + s10 + s11 + s12 - 1 + DJU, data = conso_lm)
```

Residuals:

Min	1Q	Median	3Q	Max
-1626.9	-521.5	-115.2	488.1	2838.0

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
time	-1.493	2.972	-0.502	0.617
s1	35813.991	906.167	39.523	<2e-16 ***
s2	32735.317	846.452	38.674	<2e-16 ***
s3	33709.936	691.500	48.749	<2e-16 ***
s4	30151.066	523.577	57.587	<2e-16 ***
s5	30399.377	405.760	74.920	<2e-16 ***
s6	31373.101	330.086	95.045	<2e-16 ***
s7	33773.656	318.705	105.971	<2e-16 ***
s8	31112.946	321.857	96.667	<2e-16 ***
s9	30796.635	349.295	88.168	<2e-16 ***
s10	31559.118	458.817	68.784	<2e-16 ***
s11	31957.239	696.362	45.892	<2e-16 ***
s12	34166.294	840.052	40.672	<2e-16 ***
DJU	43.372	2.202	19.699	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 789.6 on 82 degrees of freedom

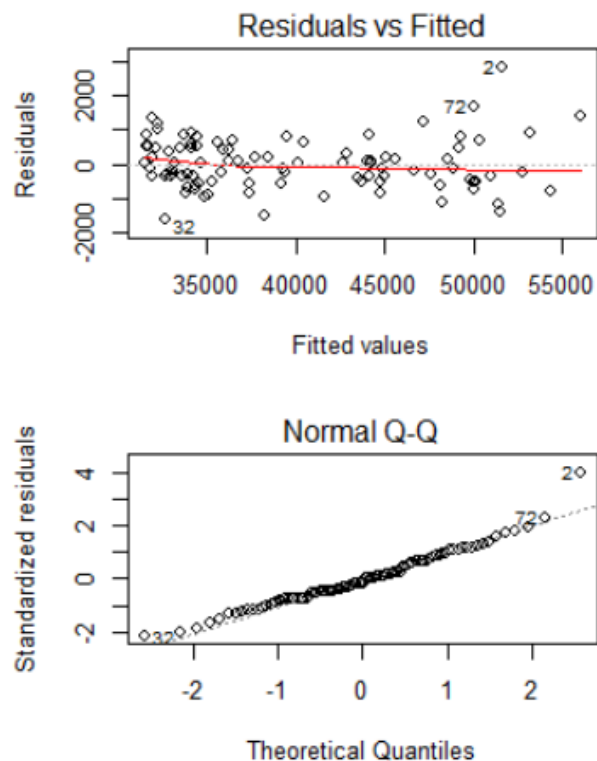
Multiple R-squared: 0.9997, Adjusted R-squared: 0.9996
F-statistic: 1.817e+04 on 14 and 82 DF, p-value: < 2.2e-16

On récupère le
coefficient b de
notre modèle

Tests de validités


studentized Breusch-Pagan test

data: fit
BP = 16.915, df = 13, p-value = 0.2032



Shapiro-Wilk normality test

data: fit\$residuals
W = 0.97464, p-value = 0.05936




Modèle corrigé

$$y_{\text{corrigé}} = y - bu = at + \sum_{i=1}^{12} C_i 1$$

```
#J'ajoute une colonne qui donne la consommation corrigée de l'effet  
#température  
conso$Conso_adj<-conso$Conso - conso$DJU*fit$coefficients[["DJU"]]
```

Date	Territoire	Qualité	Conso	time	DJU	Conso_adj
2012-01	France	Données définitives	51086	1	336.0	36513.14
2012-02	France	Données définitives	54476	2	435.9	35570.32
2012-03	France	Données définitives	43156	3	210.5	34026.28
2012-04	France	Données définitives	40176	4	231.2	30148.49
2012-05	France	Données définitives	35257	5	93.8	31188.74
2012-06	France	Données définitives	33219	6	50.4	31033.07

Consommation corrigée de l'effet température vs consommation réelle




Dessaisonalisation

« grâce au moyenne mobile »

Décomposition

```
#J'utilise la fonction decompose pour étudier ma série temporelle  
decomp_conso_adj<-decompose(ts_conso_adj)  
plot(decomp_conso_adj)
```




Dessaisonalisation

```
#Je crée une colonne avec la consommation dessaisonnalisée  
conso$deseasonal<-conso$Conso_adj - conso$seasonal
```

Date	Territoire	Qualité	Conso	time	DJU	Conso_adj	deseasonal
2012-01	France	Données définitives	51086	1	336.0	36513.14	33059.26
2012-02	France	Données définitives	54476	2	435.9	35570.32	35505.62
2012-03	France	Données définitives	43156	3	210.5	34026.28	32626.01
2012-04	France	Données définitives	40176	4	231.2	30148.49	32257.18
2012-05	France	Données définitives	35257	5	93.8	31188.74	33159.99
2012-06	France	Données définitives	33219	6	50.4	31033.07	31863.88

Consommation corrigée vs consommation corrigée et désaisonnalisée




Prévision de la consommation méthode Holt-Winters

« résultats, analyses »


Décomposition

```
#J'utilise le lissage exponentiel Holt winter pour effectuer des  
#prédictions  
hw<-ets(ts_conso_adj, model = "ZZZ")
```

Decomposition by ETS(M,N,A) method



Courbe de prédiction



Analyse du modèle

ETS(M,N,A)

Call:

```
ets(y = ts_conso_adj, model = "ZZZ")
```

Smoothing parameters:

alpha = 1e-04

gamma = 0.0023

Initial states:

l = 32246.5919

s = 1960.557 -331.9638 -741.9747 -1471.627 -1074.929 1549.063
-787.3409 -1994.793 -2065.057 1402.805 386.6649 3168.596

sigma: 0.0248

AIC	AICc	BIC
1735.966	1741.966	1774.432

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-23.32789	742.9247	574.2253	-0.1325487	1.771785	0.6437558

ACF1

Training set 0.02388857


Tests de validités

Test Q de Ljung-Box :

Retard	p-value
6	0.76714
12	0.62892
18	0.33000
24	0.41346
30	0.32081
36	0.31231

Shapiro-Wilk normality test

data: pred_hw\$residuals
W = 0.96965, p-value = 0.02514




Prévision de la consommation méthode SARIMA

« résultats, tests, analyses »


(I)

```
#J'étudie l'autocorrelogramme de ma série pour étudier comment la série  
#doit être différenciée  
acf(ts_conso_adj, lag.max=72, plot=TRUE)
```




$$(1 - B^{12})$$

```
#J'effectue une différenciation de lag = 12  
y_dif_12=diff(ts_conso_adj,lag=12,differences=1)
```



Partial ACF



Classement des différents modèles

```

pmax = 4
qmax = 4
Pmax = 0
Qmax = 1
i<-1
c<-data.frame()

for (p in 0:pmax) {
  for (q in 0:qmax) {
    for (p12 in 0:Pmax) {
      for (q12 in 0:Qmax) {
        model1=try(Arima(ts_conso_adj,order=c(p,0,q),
          list(order=c(p12,1,q12),period=12),
          include.mean=TRUE,method="CSS-ML"),TRUE)
        if (class(try(length(t_stat(model1)),TRUE)) == "integer"){
          if (length(t_stat(model1)) == 0){
            c[i,"nom_model"]<-paste("model(",p,"0",q,")(",p12,"1",q12,")",
              sep = ",")
            c[i,"aic"]<-model1$aic
            c[i,"bic"]<-model1$bic
            c[i,"RMCE"]<-(model1$residuals)^2>%mean()%>%.^0.5
            i<-i+1
          }
          else if (length(t_stat(model1)[2,]) ==
            try((t_stat(model1)[2,]<0.05)%>%as.numeric()%>%sum())) {
            c[i,"nom_model"]<-paste("model(",p,"0",q,")(",p12,"1",q12,")",
              sep = ",")
            c[i,"aic"]<-model1$aic
            c[i,"bic"]<-model1$bic
            c[i,"RMCE"]<-(model1$residuals)^2>%mean()%>%.^0.5
            i<-i+1
          }
        }
      }
    }
  }
}

```

nom_model	aic	bic	RMCE
model(203)(011)	1383.764	1400.780	731.1075
model(202)(011)	1386.271	1400.856	741.5489
model(000)(011)	1386.326	1391.188	772.1475
model(101)(011)	1390.152	1399.875	774.0849
model(202)(010)	1404.275	1416.430	881.6530
model(203)(010)	1406.973	1421.558	885.8001
model(000)(010)	1415.787	1418.217	1022.2439

Modèle choisi

Series: ts_conso_adj
ARIMA(0,0,0)(0,1,1)[12]

Coefficients:

 sma1
 -0.8714
s.e. 0.2563

sigma^2 estimated as 689594: log likelihood=-691.16
AIC=1386.33 AICc=1386.47 BIC=1391.19

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-82.77066	772.1475	596.4574	-0.2974778	1.852959	0.6686799

 ACF1
Training set 0.01903371


Tests de validités

Test Q de Ljung-Box :


Retard	p-value
6	0.77869
12	0.49150
18	0.22727
24	0.34362
30	0.32006
36	0.39712

Shapiro-Wilk normality test

data: model2\$residuals
W = 0.98952, p-value = 0.6535



Courbe de prédiction



Auto SARIMA

```
#J'utilise une fonction qui permet de trouver des modèles performants  
#de façon automatique  
model2<-auto.arima(ts_conso_adj)
```

```
Series: ts_conso_adj  
ARIMA(0,0,0)(0,1,1)[12]
```

```
Coefficients:
```

```
      sma1  
      -0.8714  
s.e.    0.2563
```

```
sigma^2 estimated as 689594:  log likelihood=-691.16  
AIC=1386.33   AICc=1386.47   BIC=1391.19
```

```
Training set error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-82.77066	772.1475	596.4574	-0.2974778	1.852959	0.6686799

```
      ACF1  
Training set 0.01903371
```

Conclusion

Le modèle **SARIMA(0,0,0)(0,1,1)[12]** est un peu moins précis mais me semble plus sûre, un critère d'Akaike beaucoup plus faible et une normalité des résidus très forte.

Je choisis donc le modèle **SARIMA(0,0,0)(0,1,1)[12]**

Bilan

Ce projet m'a permis d'apprendre de nombreuses choses sur les séries temporelles et leurs méthodes de prédictions.

Une étude uniquement sur une région et prenant en compte les DJU climaticien m'aurait paru plus fiable.